
Visualización de Evolución en el Tiempo

Pipeline ETL con OpenRefine + Dashboard en Power BI

Estudiante	Daniel Arbeláez Álvarez
Asignatura / Módulo	Visualización interactiva de la información
Fecha de entrega	14-05-2026
Herramientas	OpenRefine 3.7+ · Power BI Desktop · DAX · GREL
Dataset	<code>datos_ventas.csv</code> — 18,000 filas · 15 columnas
Transformaciones ETL	100 operaciones registradas (Undo/Redo 100/100)
Visualizaciones	5 gráficos · 3 medidas DAX · Tabla Calendario

Proyecto de análisis de datos aplicado: limpieza, normalización y visualización temporal de un dataset de ventas comerciales usando herramientas de Business Intelligence.

Índice de Contenidos

1. Descripción del Dataset Utilizado
2. Fase 1: Limpieza y Transformación de Datos en OpenRefine
3. Fase 2: Visualización de Datos en Power BI
4. Análisis e Interpretación de Resultados

1. Descripción del Dataset Utilizado

- **Origen de los datos:** Archivo `datos_ventas.csv`
- **Dimensiones:** 18,000 filas.
- **Contenido principal:** Registros de ventas que incluyen variables categóricas (Categoría, Ciudad, Método de Pago, Estado) y variables cuantitativas (Precio Unitario, Cantidad).
- **Objetivo:** Preparar estos datos eliminando inconsistencias (como caracteres especiales *, ?, _) para analizar su evolución temporal en un dashboard.

OpenRefine datos ventas csv Permalink

Facet / Filter Undo / Redo 3 / 3 18,000 rows Extensions Wikibase

Show as: rows records Show: 5 10 25 50 100 500 1000 rows

		ID_Venta	Producto	Ciudad	Categoría	Precio_Unitario	Cantidad	Fecha_Venta	Cliente	Email	Telefono	Dirección
1.	28	owner	East Jonathan	TV	2400	22	2023-11-20	Daniel Garcia	edward94@example.org	001-419-330-3873x873497	USS Fuller	PPO AA 30334
2.	20	education	Trugilofort	spring	600	18	2023-01-04	Larry Welch	powersjimmy@example.org	(175)317-5834	03146 Tony Spring Apt	Eidberg AK 73272
3.	25	strategy	Nguyenshine	group	900	28	2023-05-05	Kelsey Lopez	estesjon@example.org	857-262-8794	493 Cameron Ramp	Veronictown, MI 8101
4.	9	present	South Thomas	budget	700	27	2023-06-28*	Sharon Lowe	estesjon@example.org	?001-594-337-5421x87814	29882 Stein Tunnel Ap	Port Jacquelineville, H
5.	9	song	New Reginaldmouth	at	200	29	2023-07-08	Alan Bird	edward94@example.org	001-236-332-5014x39284	30768 Louis Mill	Lake Carmen, LA 479
6.	5	wait*	Valerietown	*whom	1300	27	2023-06-28	Crystal Chambers	estesjon@example.org	857-262-8794	283 Cynthia Groves At	Wearmouth, ID 067
7.	21	under	Lindaport	_whom	1300	14	2023-07-10?	David Norton	powersjimmy@example.org	857-262-8794	9978 Kenneth Plaza S	Monicafurt, NM 39529
8.	10	*democratic	Milesburgh	*leader	200	11	2023-06-06	Michelle Mitchell	estesjon@example.org	280 504 6212	30768 Louis Mill	Lake Carmen, LA 479
9.	19	door_	Jodichester?	budget?	300	22	2023-06-17	Alan Bird	yddavid@example.com	+1-105-592-6193x7727_	915 Mathis Camp Apt	Thomastown, MS 443
10.	17	door	East Jonathan	individual_	300	25	2023-07-25	Lisa Stafford	*rdaugherly@example.net	870-860-0083x698	USS Fuller	PPO AA 30334

2. Fase 1: Limpieza y Transformación de Datos en OpenRefine

2.1 Identificación de Problemas (Exploración y Diagnóstico)

El dataset cargado en OpenRefine (18,000 filas) mostró caracteres sucios visibles desde la primera pantalla: `wait*`, `*democratic`, `door_` en `Producto`; `Jodichester?` en `Ciudad`; `*whom`, `_whom`,

*leader, budget? en Categoría; fechas con * y ? en Fecha_Venta; emails con * al inicio. Se aplicaron Facets para medir el alcance real antes de transformar.

Columnas Categóricas — Text Facets

- Paso 1.1 - Categoría:** El Text facet devolvió **227 opciones únicas** en una columna que debería tener 30 valores. Cada variante sucia (*whom, _whom, budget?, individual_, *job, *leader) contaba como un valor independiente. Se usó Cluster and edit con Key collision y función Fingerprint para agrupar y unificar.

ID_Venta	Producto	Ciudad	Categoría	Precio_Unitario	Cantidad	Fecha_Venta	Cliente	Email	Telefono	Direccion
1	owner	East Jonathan				3-11-20	Daniel Garcia	edward94@example.org	001-419-330-3873x873497	USS Fuller FPO AA 30334
2	education	Trujillofort				3-01-04	Larry Welch	powersjimmy@example.org	(175)317-5634	03346 Tony Spring Apt Ericberg, AK 73272
3	strategy	Nguyenshire				3-05-05	Kelsey Lopez	estesjon@example.org	857-262-8794	493 Cameron Ramp Veronicatown, MI 8101
4	present	South Thomas				3-06-20	Sharon Lowe	estesjon@example.org	7001-594-337-5421x87814	29082 Stein Tunnel Apt Port Jacquelineville, HI
5	song	New Reginaldmouth				3-07-08	Alan Bird	edward94@example.org	001-236-332-5014x39284	30768 Louis Mill Lake Carmen, LA 479
6	wall	Valerietown				3-06-28	Crystal Chambers	estesjon@example.org	857-262-8794	283 Cynthia Groves At Weavermouth, ID 067
7	under	Lindaport				2023-07-107	David Norton	powersjimmy@example.org	857-262-8794	6979 Kenneth Plaza S Monicaturf, NM 39529
8	*democratic	Milesburgh	*leader	200	11	2023-06-06	Michelle Mitchell	estesjon@example.org	280 504 6212	30768 Louis Mill Lake Carmen, LA 479
9	door_	Jodichester?	budget?	300	22	2023-06-17	Alan Bird	ydavid@example.com	+1-105-592-6193x7727_	915 Mathis Camp Apt Thomastown, MS 443
10	door	East Jonathan	individual_	300	25	2023-07-25	Lisa Stafford	*rdaugherly@example.net	870-860-8083x698	USS Fuller FPO AA 30334

Facet / Filter
Undo / Redo 3 / 3

Refresh
Reset all
Remove all

Categoría
change

227 choices Sort by: name count
Cluster

budget 20
exist 17
finish 19
grow 16
increase 20
individual 17
industry 17
job 19
leader 13
leg 18
letter 11
movement 27

El diálogo de clustering identificó 28 grupos de variantes. Se confirmaron los merges.

OpenRefine datos ventas.csv Permalink

Facet / Filter Undo / Redo 1 / 3 < 18,000 rows

Refresh Reset all Remove all Show as: rows records Show: 5 10 25 50 100 500 1000 rows e first e previous 1 - 10 next last

Extensions Wikibase

Facet - Categoria 227 choices Sort by: name count

Cluster and edit column "Categoria"

Find groups of different cell values that might be other representations of the same thing. For example, "New York" and "new york" likely refer to the same concept and just differ by capitalization, and "Godef" and "Godel" probably refer to the same person. [Find out more...](#)

Method: Key collision Keying function: Fingerprint Manage clustering functions

☐ Auto-update 20 clusters found

Merge?	Values in cluster	New cell value	Cluster size	Row count
☐	☐ leader (427 rows) ☐ leader (26 rows) ☐ leader* (25 rows) ☐ leader (24 rows) ☐ leader? (20 rows) ☐ leader (19 rows) ☐ leader (19 rows) ☐ leader (18 rows) ☐ *leader (18 rows) ☐ leader_ (18 rows) ☐ leader (13 rows)	leader	11	627
☐	☐ TV (408 rows) ☐ TV (28 rows) ☐ ?TV (28 rows) ☐ TV (26 rows) ☐ TV (20 rows) ☐ TV (18 rows) ☐ TV* (18 rows) ☐ *TV (17 rows) ☐ TV? (17 rows)	TV	11	609

Select all Deselect all Export clusters Merge selected & re-cluster Merge selected & Close Close

Choices in cluster: 9 — 11

Rows in cluster: 564 — 655

Average length of choices: 2.9 — 10.91

Length variance of choices: 0.2874 — 0.3143

Telefono: 001-419-330-3873x87349? USS Fuller
 (175)317-5834 03348 Tony Spring
 857-262-8794 03348 Tony Spring
 7001-594-337-5421x87814 493 Cameron Ram
 001-236-332-5014x39284 Port Jacquelinville
 857-262-8794 30768 Louis Mill
 288 504 6212 283 Cynthia Groves
 +1-105-592-6193x7727_ 9978 Kenneth Plaza
 870-860-8083x698 Lake Carmen, LA 47
 USS Fuller FPO AA 30334

Categoria quedó en **30 valores canónicos** (at, budget, individual, job, leader, TV, whom).

Facet / Filter
Undo / Redo 4 / 4

Refresh
Reset all
Remove all

x
Categoria
change

30 choices
Sort by: name count
Cluster

at 598
budget 580
despite 617 edit include
exist 583
finish 579
forward 651
group 605
grow 594
increase 571
individual 655
industry 603
job 586
leader 627
leg 578
letter 590
matter 627
member 573
movement 611
much 625
north 596
pay 604
popular 622
rich 618
say 564
set 564
spring 580
step 573
still 594
TV 609
whom 623
Facet by choice counts

- Paso 1.2 - Ciudad:** El **Text facet** post-limpieza confirma 30 ciudades sin signos de interrogación. Los valores sucios (**Jodichester?**, **East Brittany?**) visibles en la captura inicial fueron eliminados con las transformaciones GREL.

Ciudad		change
30 choices Sort by: name count		Cluster
Andrewside	602	
Brendanberg	575	
Briannaport	611	
Courtneymouth	583	
East Brittany	641	
East Janicemouth	608	
East Jonathan	579	
East Josephland	602	edit include
East Leah	628	
Jessechester	555	
Jodichester	607	
Kevinton	621	
Lake Juan	602	
Larrychester	636	
Lindaport	599	
Milesburgh	618	
New Reginaldmouth	591	
Nguyenshire	619	
North Brittney	591	
North Jasmine	582	
North Thomastown	617	
Port Alexachester	559	
Port Kelly	592	
South Thomas	579	
South Timothyberg	625	
Susanton	582	
Trujillofort	574	
Valerietown	617	
Vasquezborough	626	
West Charles	579	
Facet by choice counts		

- **Paso 1.3 - Metodo_Pago:** Resultado post-limpieza: 2 valores canónicos, **Efectivo** (8,383 registros) y **Tarjeta** (9,617). Sin variantes sucias residuales.

Metodo_Pago		change
2 choices Sort by: name count		Cluster
Efectivo	8383	
Tarjeta	9617	
Facet by choice counts		

- **Paso 1.4 - Estado:** Resultado post-limpieza: **En camino** (6,593) y **Entregado** (11,407). Los valores corruptos **En?cami** y **En cam*** fueron corregidos con GREL.


Estado		change
2 choices Sort by: name count		Cluster
En camino	6593	
Entregado	11407	
Facet by choice counts		

Columnas Numéricas — Numeric Facets

- **Paso 1.5 - Precio_Unitario:** El **Numeric facet** no permitía transformaciones directas en esta columna. Se usó **Text facet**, que confirmó 18 valores numéricos únicos (de 200 a 3000) sin texto mezclado.

Precio_Unitario		change
18 choices Sort by: name count		Cluster
1100	1183	
1300	1182	
1500	1207	
1600	563	
200	1805	
2000	620	
2100	1175	
2300	600	
2400	623	
2500	1194	
2600	580	
2800	588	
300	1237	
3000	620	
600	650	
700	2358	
800	605	
900	1210	
Facet by choice counts		

- **Paso 1.6 - Cantidad:** Mismo caso que **Precio_Unitario**. Se aplicó primero `value.replace(/\s+/, "")` para eliminar espacios embebidos, luego **Text facet** para validar. Resultado: 23 enteros limpios (del 2 al 30).



Cantidad		change
23 choices Sort by: name count		Cluster
10	612	
11	1852	
12	536	
13	581	
14	626	
15	607	
16	1201	
17	613	
18	642	
2	571	
21	1211	
22	1178	
23	1124	
24	632	
25	582	
26	565	
27	1230	
28	633	
29	618	
30	622	
7	584	
8	596	
9	584	
Facet by choice counts		

Columna Email — Clustering por n-Gram

- **Paso 1.7 - Email:** Cluster and edit con Key collision y n-Gram fingerprint (tamaño 1) detectó **29 clusters** donde el @ había sido reemplazado por un espacio (ej: schmidtkrystal@example.org vs schmidtkrystal example.org). Se consolidaron todos al valor correcto.

Cluster and edit column "Email"

Find groups of different cell values that might be other representations of the same thing. For example, "New York" and "new york" likely refer to the same concept and just differ by capitalization, and "Gödel" and "Godel" probably refer to the same person. [Find out more...](#)

Method: **Key collision** Keying function: **n-Gram fingerprint** Manage clustering functions n-Gram size: **1**

☐ Auto-update 29 clusters found

Merge?	Values in cluster	New cell value	Cluster size	Row count
☒	☒ schmidtkrystal@example.org (623 rows) ☒ schmidtkrystal example.org (9 rows)	schmidtkrystal@example.org	2	632
☒	☒ rbrown@example.org (598 rows) ☒ rbrown example.org (10 rows)	rbrown@example.org	2	608
☒	☒ eric24@example.com (575 rows) ☒ eric24 example.com (14 rows)	eric24@example.com	2	589
☒	☒ powersjimmy@example.org (592 rows) ☒ powersjimmy example.org (13 rows)	powersjimmy@example.org	2	605
☒	☒ david09@example.com (594 rows) ☒ david09 example.com (9 rows)	david09@example.com	2	603

Rows in cluster

Average length of choices

Valores Nulos — Facet by Blank

- **Paso 1.8 - Nulos:** Facet by blank en todas las columnas críticas midió el volumen de datos faltantes.

Documentación y Justificación del Diagnóstico

Paso realizado: Exploración mediante Text Facets en columnas categóricas (Categoría, Ciudad, Metodo_Pago, Estado). **Ruta:** Encabezado de columna ▼ → Facet → Text facet

Justificación lógica: El Text Facet genera un inventario de todos los valores únicos de una columna. Un valor como Efectivo y Efectivo se ven casi iguales en pantalla, pero Power BI los trata como categorías distintas: aparecen dos barras donde debería haber una. Esta vista expone esos errores antes de que contaminen cualquier visualización.

Paso realizado: Exploración de columnas numéricas mediante Numeric Facets

(Precio_Unitario, Cantidad). **Ruta:** Encabezado de columna ▼ → Facet → Numeric facet

Justificación lógica: El Numeric Facet genera un histograma con una barra separada para valores "Non-numeric". Si Precio_Unitario o Cantidad contienen texto mezclado, Power BI no puede sumarlos ni calcular promedios. Detectar esos casos antes de importar evita errores silenciosos en las medidas DAX.

Paso realizado: Identificación de celdas vacías mediante Facet by Blank. **Ruta:** Encabezado de columna ▼ → Facet → Customized facets → Facet by blank **Justificación lógica:**

Cuantifica los datos faltantes por columna. Un nulo en un segmentador de Power BI genera una fila en blanco; en una medida DAX puede devolver BLANK donde se espera un número. Conocer cuántos hay define la estrategia: eliminar filas, imputar un valor por defecto, o etiquetar como "Sin dato".

2.2 Transformaciones Aplicadas (Corrección y Normalización)

Fase 2 — Normalización de Espacios y Capitalización

Paso 2.1 — Eliminar espacios al inicio/final en columnas categóricas

Paso realizado: Eliminación de espacios en blanco al inicio y al final en columnas categóricas (Producto, Ciudad, Categoría, Cliente, Metodo_Pago, Estado)

Ruta o Comando GREL: Encabezado de columna ▼ → Edit cells → Common transforms → Trim leading and trailing whitespace

Justificación lógica: Se detectó mediante Text Facets la presencia de espacios en blanco al inicio y/o final de valores en múltiples columnas categóricas. Estos espacios invisibles hacen que Power BI interprete " Efectivo" y "Efectivo" como dos categorías completamente distintas, generando duplicados en gráficas de barras, segmentadores y tablas dinámicas. La función `trim()` elimina estos espacios superfluos, garantizando la unicidad real de cada categoría y la integridad de los filtros en el modelo de datos.

Paso 2.2 — Colapsar espacios internos múltiples

Paso realizado: Colapso de espacios internos múltiples en columnas de texto libre (Ciudad, Cliente, Direccion)

Ruta o Comando GREL: Edit cells → Transform... → `value.replace(/\s+/, " ")`

Justificación lógica: Se identificaron celdas con doble o triple espacio entre palabras, producto de errores de captura manual de datos. Un doble espacio, aunque visualmente similar, genera una cadena de texto diferente que impide la correcta agrupación en Power BI. La expresión regular `/\s+/` captura uno o más espacios consecutivos y los reemplaza por un único espacio normalizado, asegurando la consistencia de los valores de texto para operaciones de agrupación, búsqueda y filtrado.

Custom text transform on column Ciudad

Expression

Language

General Refine Expression Language (GREL) ▼

value.replace(/\\s+/, " ")

No syntax error.

Preview

History

Starred

Help

row	value	value.replace(/\\s+/, " ")
1.	East Jonathan	East Jonathan
2.	Trujillofort	Trujillofort
3.	Nguyenshire	Nguyenshire
4.	South Thomas	South Thomas
5.	New Reginaldmouth	New Reginaldmouth
6.	Valerietown	Valerietown

On error

☒ keep original
 ☐ set to blank
 ☐ store error

☐ Re-transform up to

 times until no change

OK

Cancel

Paso 2.3 — Normalizar texto a formato Título (`toTitlecase()`)

Paso realizado: Normalización de texto a formato Título (`toTitlecase()`) en columnas de nombres propios (`Producto`, `Ciudad`, `Cliente`, `Categoría`)

Ruta o Comando GREL: `Edit cells` → `Transform...` → `value.toTitlecase()`

Justificación lógica: Se encontraron valores con inconsistencias de capitalización. La captura muestra la transformación sobre `Producto` (`owner` → `Owner`, `education` → `Education`, `strategy` → `Strategy`). La función `toTitlecase()` coloca mayúscula únicamente en la primera letra de cada palabra. Esta normalización es necesaria porque el motor de Power BI distingue entre mayúsculas y minúsculas al agrupar datos; sin ella, un mismo producto o ciudad aparecería varias veces con nombres distintos en los gráficos.

Custom text transform on column Producto

Expression

Language

General Refine Expression Language (GREL) ▼

value.toTitlecase()

No syntax error.

Preview

History

Starred

Help

row	value	value.toTitlecase()
1.	owner	Owner
2.	education	Education
3.	strategy	Strategy
4.	present	Present
5.	song	Song
6.	wait	Wait

On error

☒ keep original
 ☐ set to blank
 ☐ store error

☐ Re-transform up to

10

 times until no change

OK

Cancel

Normalización de Capitalización Específica

Paso 2.4 — Normalizar texto a minúsculas (`toLowerCase()`) en `Email` y `Metodo_Pago`

Paso realizado: Normalización de texto a minúsculas (`toLowerCase()`) en las columnas `Email` y `Metodo_Pago`

Ruta o Comando GREL: `Edit cells` → `Transform...` → `value.toLowerCase()`

Justificación lógica: Los correos electrónicos son por estándar técnico (RFC 5321) insensibles a mayúsculas, pero como cadena de texto son tratados como valores distintos:

"Pedro@Example.com" y "pedro@example.com" no se consolidarían como el mismo cliente. La misma lógica aplica a `Metodo_Pago`, donde `Efectivo` y `efectivo` deben converger en un único valor canónico. La captura muestra la transformación sobre `Metodo_Pago` (`Efectivo` → `efectivo`, `Tarjeta` → `tarjeta`).

Custom text transform on column Metodo_Pago

Expression

Language General Refine Expression Language (GREL) ▾

value.toLowerCase()

No syntax error.

Preview

History

Starred

Help

row	value	value.toLowerCase()
1.	Efectivo	efectivo
2.	Efectivo	efectivo
3.	Efectivo	efectivo
4.	Efectivo	efectivo
5.	Tarjeta	tarjeta
6.	Efectivo	efectivo

On error

☒ keep original
 ☐ set to blank
 ☐ store error

☐ Re-transform up to times until no change

OK

Cancel

Eliminación de Caracteres Especiales

Paso 2.5 — Eliminar caracteres especiales sucios (*, _, ?) en columnas categóricas

Paso realizado: Eliminación de caracteres especiales no válidos (*, _, ?) al inicio y final de valores en columnas categóricas (**Producto**, **Ciudad**, **Categoría**, **Metodo_Pago**, **Estado**, **Cliente**, **Email**, **Fecha_Venta**)

Ruta o Comando GREL: `Edit cells → Transform... → value.replace(/^[*_?]+|[*_?]+$/ , "").trim()`

Justificación lógica: Durante la exploración con Text Facets se identificaron valores contaminados con caracteres especiales (*, _, ?) en posiciones de inicio o final de la cadena (ej: ***Tarjeta**, **_Efectivo**, **budget?**). Estos caracteres son producto de errores en el sistema de origen o en la exportación del archivo. La expresión regular `^[*_?]+|[*_?]+$` apunta específicamente a estas posiciones sin alterar el contenido central del dato. Su eliminación es crítica porque Power BI los trataría como categorías únicas y distintas, rompiendo cualquier análisis comparativo o de tendencias.

Custom text transform on column Ciudad

Expression

Language General Refine Expression Language (GREL) ▾

value.replace(/^[*_?]+|[*_?]+\$/, "").trim()

No syntax error.

Preview

History

Starred

Help

row	value	value.replace(/^[*_?]+ [*_?]+\$...
1.	East Jonathan	East Jonathan
2.	Trujillofort	Trujillofort
3.	Nguyenshire	Nguyenshire
4.	South Thomas	South Thomas
5.	New Reginaldmouth	New Reginaldmouth
6.	Valerietown	Valerietown

On error

☒ keep original
 ☐ set to blank
 ☐ store error

☐ Re-transform up to times until no change

OK

Cancel

2.3 Transformaciones Avanzadas (Tipos y Nulos)

Fase 4 — Conversión de Tipos de Dato y Manejo de Nulos

Paso 4.1 — Convertir Fecha_Venta a tipo Fecha

Paso realizado: Conversión de Fecha_Venta al tipo dato Fecha

Ruta: Encabezado de columna ▾ → Edit cells → Common transforms → To date

Justificación lógica: OpenRefine almacena las fechas como texto por defecto. Si Fecha_Venta llega a Power BI como texto, el modelo no puede construir jerarquías de tiempo (año/trimestre/mes) ni usar funciones de inteligencia temporal en DAX como DATESYTD o DATEADD. La conversión aquí garantiza que Power BI la reconozca como dimensión de tiempo al importar, sin pasos adicionales en Power Query.

18,000 rows

Extensions Wikibase

Show as: rows records Show: 5 10 25 50 100 500 1000 rows

« first < previous 1 - 10 next > last »

All	ID_Venta	Producto	Ciudad	Categoria	Precio_Unitario	Cantidad	Fecha_Venta	Cliente	Email	Telefono	Direccion
1.	28	Owner	East Jonathan	Tv	2400	22		el Garcia	edward94@example.org	001419330387387349	USS Fuller FPO AA 3
2.	20	Education	Trujillofort	Spring	600	18		Welch	powersjimmy@example.org	1753175834	03346 Tony Spring Ap
3.	25	Strategy	Nguyenshire	Group	900	28		by Lopez	estesion@examole.org	8572628794	493 Cameron Ramp \
4.	9	Present	South Thomas	Budget	700	27				001594337542187814	29882 Stein Tunnel A
5.	9	Song	New Reginaldmouth	At	200	29					Mill Lake
6.	5	Wait	Valerietown	Whom	1300	27					Groves A
7.	21	Under	Lindaport	Whom	1300	14					h Plaza 5
8.	10	Democratic	Milesburgh	Leader	200	11					Mill Lake
9.	19	Door	Jodichester	Budget	300	22					camp Apt
10.	17	Door	East Jonathan	Individual	300	25					PO AA 3

Facet

Q Text filter

Edit cells

Edit column

Transpose

Sort...

Hide / Show

Reconcile

Common transforms

Trim leading and trailing whitespace

Collapse consecutive whitespace

Unescape HTML entities

Replace smart quotes with ASCII

To titlecase

To uppercase

To lowercase

To number

To date

To text

To null

To empty string

Los valores en verde con formato ISO (2023-11-20T00:00:00Z) confirman que OpenRefine reconoció el tipo correctamente. Power BI interpreta ese formato sin configuración adicional.

Inicio	Cantidad	Fecha_Venta	Cliente
	22	2023-11-20T00:00:00Z	Daniel Garcia
	18	2023-01-04T00:00:00Z	Larry Welch
edit	28	2023-05-05T00:00:00Z	Kelsey Lopez
	27	2023-06-28T00:00:00Z	Sharon Lowe
	29	2023-07-08T00:00:00Z	Alan Bird
	27	2023-06-28T00:00:00Z	Crystal Chambers
	14	2023-07-10T00:00:00Z	David Norton
	11	2023-06-06T00:00:00Z	Michelle Mitchell
	22	2023-06-17T00:00:00Z	Alan Bird
	25	2023-07-25T00:00:00Z	Lisa Stafford


Paso 4.2 — Imputar valores nulos en Comentario

Paso realizado: Sustitución de valores nulos en Comentario con el texto "Sin comentario"

Ruta / GREL: Edit cells → Transform... → if(isBlank(value), "Sin comentario", value)

Justificación lógica: Los nulos en columnas de texto generan filas en blanco en los segmentadores de Power BI y comportamiento inesperado en tablas. Reemplazarlos con una

etiqueta explícita convierte el nulo en un valor manejable: aparece como categoría en los filtros en lugar de desaparecer silenciosamente.



2.4 Exportación del Dataset Limpio

Fase 5 — Exportación Final a Power BI

Paso 5.1 — Eliminar todos los filtros activos

Paso realizado: Eliminación de todos los Facets activos antes de exportar

Ruta: Panel Facet/Filter → Remove All

Justificación lógica: Si algún Facet queda activo al exportar, OpenRefine solo exporta las filas visibles. El archivo se descarga sin advertencias pero con menos de 18,000 registros. El contador superior debe mostrar **18,000 rows** antes de proceder.

Paso 5.2 — Exportar como CSV

Paso realizado: Exportación del dataset limpio en formato CSV

Ruta: Export → Comma-separated value (CSV)

Justificación lógica: El CSV es el estándar universal de intercambio de datos tabulares, compatible con Power BI sin transformaciones adicionales. Power Query detecta los tipos automáticamente y las fechas en formato ISO (**2023-11-20T00:00:00Z**) son reconocidas sin configuración extra.

					Open...	Export ▾	Help
					OpenRefine project archive to file		
					Tab-separated value		
					Comma-separated value		
					HTML table		
					Excel (.xls)		
					Excel 2007+ (.xlsx)		
					ODF spreadsheet		
					Custom tabular...		
					SQL...		
					Templating...		
					Wikibase edits...		
					QuickStatements file		
					Wikibase schema		
					Entregado	Producto detectado	
					Entregado	Sin comentario	27
					Entregado	Sin comentario	12

Resumen Ejecutivo — Proceso ETL Completado

Fase Descripción Acciones principales

Fase 1 Exploración y Diagnóstico Text Facets, Numeric Facets, Facet by Blank **Fase 2** Limpieza básica `trim()`, `replace(/\\s/, " ")`, `toTitlecase()`, `toLowerCase()`, limpieza de `*`, `_`, `?` **Fase 3** Clustering Key Collision (fingerprint, n-gram), Nearest Neighbor (levenshtein) en 5 columnas **Fase 4** Transformaciones avanzadas `To number`, `To date` en `Fecha_Venta`, imputación de nulos en `Comentario` **Fase 5** Exportación Remove All Export CSV verificación en Power BI


Total de transformaciones registradas: 100 operaciones (Undo/Redo 100/100)

3. Fase 2: Visualización de Datos en Power BI


3.0 Importación y Modelado en Power Query

A — Carga y Verificación de Tipos en Power Query

El CSV exportado de OpenRefine se importó a Power BI mediante `Obtener datos → Texto/CSV`. La vista previa de Power Query confirmó las 18,000 filas completas con tipos detectados automáticamente.



En el editor de Power Query se aplicaron dos ajustes antes de cargar al modelo: se marcó **ID_Venta** como clave de la tabla (**Table.AddKey**) para optimizar relaciones y evitar duplicados en cruces, y se verificaron los tipos de cada columna.




Tipos confirmados: **ID_Venta** (entero, clave), **Precio_Unitario** y **Cantidad** (número), **Fecha_Venta** (Fecha/Hora), resto como texto. Con los tipos correctos, las medidas DAX operan sin conversiones implícitas.

Año	YEAR(Calendario[Date])
Mes	MONTH(Calendario[Date])
NombreMes	FORMAT(Calendario[Date], "MMMM")
Trimestre	"Q" & QUARTER(Calendario[Date])

NombreMes debe ordenarse por la columna Mes (Herramientas de columna → Ordenar por columna) para que todos los ejes temporales sigan la secuencia cronológica (enero, febrero...) y no la alfabética (abril, agosto...).

Relación creada: **Calendario[Date]** **Ventas[Fecha_Venta]** (muchos a uno, dirección única).



C — Medidas DAX

Medida 1 — Ingresos Totales

```

Ingresos_Totales
SUMX(
    Ventas,
    Ventas[Precio_Unitario] * Ventas[Cantidad] * (1 - Ventas[Descuento]
/ 100)
)

```

SUMX aplica el descuento fila por fila antes de sumar. La división /100 es necesaria porque la columna Descuento almacena porcentajes como enteros (ej: 21 21%), no como decimales (0.21). Sin esta corrección, (1 - 21) -20 convierte todos los ingresos en valores negativos de varios miles de millones.

Medida 2 — Variación vs. Período Anterior

```

Variacion_vs_PeriodoAnterior
VAR VentasActual    [Ingresos_Totales]
VAR VentasAnterior  CALCULATE(
    [Ingresos_Totales],
    PREVIOUSMONTH(Calendario[Date])
)
RETURN
DIVIDE(VentasActual - VentasAnterior, VentasAnterior, 0)

```

El tercer argumento de **DIVIDE** devuelve 0 en lugar de error cuando el período anterior no tiene datos.

Medida 3 — Ticket Promedio


```

Ticket_Promedio
DIVIDE(
    [Ingresos_Totales],
    DISTINCTCOUNT(Ventas[ID_Venta]),
    0
)

```

Formato aplicado a las medidas:

- **Ingresos_Totales** Moneda, 2 decimales resultado: **\$241.09 mill.**
- **Ticket_Promedio** Número, 2 decimales resultado: **8.04 mill.**
- **Variacion_vs_PeriodoAnterior** Porcentaje, 2 decimales resultado: **84.78%**




D — Ajustes y Resolución de Errores del Modelo

Durante la construcción del modelo se identificaron y corrigieron tres problemas:


Ajuste 1 — Tabla Calendario marcada como tabla de fechas

La tabla Calendario requiere ser declarada explícitamente como tabla de fechas para que las funciones de inteligencia temporal ([PREVIOUSMONTH](#), [TOTALYTD](#)) funcionen correctamente. Se activó desde [Vista Modelo](#) → [clic derecho en Calendario](#) → [Marcar como tabla de fechas](#) → [columna: Date](#).





Ajuste 2 — Medidas organizadas en carpeta dentro de tabla Ventas

Las tres medidas se crearon inicialmente en la tabla Calendario. Se movieron a la tabla [Ventas](#) y se agruparon en una carpeta [Medidas](#) para mantener el modelo organizado y facilitar su localización en el panel de campos.




Ajuste 3 — Corrección de escala en columna **Ingresos_Totales**

La versión inicial de **Ingresos_Totales** arrojó **-1,266,909,200** y **-\$19.56 mil M** — valores negativos de magnitud incoherente con el dataset.




El diagnóstico reveló que **Descuento** almacena porcentajes como enteros (21, 87, 12...), no como proporciones decimales (0.21, 0.87). La fórmula original calculaba $(1 - 21) - 20$, un multiplicador negativo aplicado a cada fila. La corrección fue agregar **/100** en la fórmula, que convierte **21** → **0.21** antes del cálculo. Tras el ajuste, **Ingresos_Totales** y **Ticket_Promedio** devuelven valores positivos y coherentes con el rango de precios del dataset: **\$241.09 mill.** en ingresos totales y **8.04 mill.** de ticket promedio sobre las 18,000 transacciones.



Ajuste 4 — Formato de porcentaje en **Variacion_vs_PeriodoAnterior**

La medida devolvía **0.85** en lugar de **85%**. Se aplicó formato de porcentaje desde **Herramientas de medición** → **Formato de datos** → **Porcentaje**, con 2 posiciones decimales. El resultado final de las 3 medidas con sus formatos definitivos: **Ingresos_Totales \$241.09 mill.**, **Ticket_Promedio 8.04 mill.** y **Variacion_vs_PeriodoAnterior 84.78%**.




Ajuste 5 — Corrección de tipo de dato en Fecha_Venta (DateTime Date)

La tabla de verificación mostraba una sola fila con **NombreMes** en blanco y **Variacion_vs_PeriodoAnterior** 0.00%: síntoma de una relación que existía pero no encontraba coincidencias. La causa: el CSV exportado tenía fechas en formato ISO con componente horario (2023-11-20T00:00:00Z), importadas por Power BI como tipo **Fecha/Hora**. La tabla **Calendario** genera valores de tipo **Fecha** puro. En Power BI, **Date** **DateTime** — la relación nunca hacía match aunque estuviera correctamente definida.

La corrección se aplicó en Power Query (**Transformar** → **Tipo de datos: Fecha**), generando el paso `Table.TransformColumnTypes(..., {"Fecha_Venta", type date})`. Como el componente horario siempre era **T00:00:00Z**, no se perdió ningún dato. Tras **Cerrar y aplicar**, la relación comenzó a funcionar y el modelo cargó correctamente por mes.

3.1 Capturas del Dashboard



3.2 Descripción de las Visualizaciones Creadas


E — Construcción de Visualizaciones del Dashboard

1. Evolución de Ingresos por Categoría (Gráfico de Líneas Multi-Serie)

Variables usadas: Eje X: **NombreMes** / **Año** (tabla Calendario) · Eje Y: **Ingresos_Totales** · Leyenda: **Categoría**

Justificación visual y psicológica: El gráfico de líneas es la codificación óptima para datos temporales continuos porque usa el canal perceptivo de posición en eje común, el de mayor expresividad según Cairo. Cada serie activa la **Ley de Continuidad de Gestalt**: el ojo sigue cada línea como una entidad separada sin esfuerzo. Se descartaron barras agrupadas porque con más de 3 series la comparación de alturas se vuelve cognitivamente costosa.

Interpretación: Revela qué categorías crecen, cuáles se estancan y si hay estacionalidad. Responde directamente la pregunta central del dashboard: ¿qué líneas de negocio impulsan los ingresos y en qué momentos?




2. Ranking de Productos por Ingresos (Barras Horizontales)

Variables usadas: Eje Y: **Producto** (orden descendente por ingresos) · Eje X: **Ingresos_Totales** (eje desde cero)

Justificación visual y psicológica: Las barras horizontales son superiores a las verticales cuando las etiquetas son nombres largos: se leen de izquierda a derecha sin rotación. Iniciar el eje en cero es un imperativo de diseño honesto (Cairo: no distorsionar magnitudes relativas). El azul uniforme aplica la **Ley de Similitud** —todas las barras son la misma categoría visual— y deja que el orden descendente, no el color, guíe la lectura del mayor al menor.

Interpretación: Evidencia el grado de concentración de ingresos. En este dataset las barras decrecen de forma gradual (de 9.5 a 5 mill.) sin un Pareto pronunciado: los ingresos están repartidos entre todo el catálogo, no concentrados en pocos productos estrella.



3. Mapa de Calor: Patrón de Ventas por Día y Mes (Matriz con Formato Condicional)

Variables usadas: Filas: **NombreMes** · Columnas: **DiaSemana** · Valores: **Ingresos_Totales** con escala blanco azul oscuro

Implementación: El día de la semana no existe como columna en el dataset original. Se crearon dos columnas calculadas en la tabla **Calendario** (no medidas, ya que describen una propiedad de cada fecha): **DiaSemana** `FORMAT(Calendario[Date], "dddd")` y **NumeroDia** `WEEKDAY(Calendario[Date], 2)`. La segunda se usó para ordenar la primera en secuencia LunesDomingo y evitar el orden alfabético.

X ✓		1 DiaSemana = FORMAT(Calendario[Date], "dddd")				
Date	Año	Mes	NombreMes	Trimestre	DiaSemana	NumeroDia
04/12/2022	2022	12	December	Q4	Sunday	7
05/12/2022	2022	12	December	Q4	Monday	1
06/12/2022	2022	12	December	Q4	Tuesday	2
07/12/2022	2022	12	December	Q4	Wednesday	3
08/12/2022	2022	12	December	Q4	Thursday	4
09/12/2022	2022	12	December	Q4	Friday	5
10/12/2022	2022	12	December	Q4	Saturday	6
11/12/2022	2022	12	December	Q4	Sunday	7
12/12/2022	2022	12	December	Q4	Monday	1
13/12/2022	2022	12	December	Q4	Tuesday	2
14/12/2022	2022	12	December	Q4	Wednesday	3
15/12/2022	2022	12	December	Q4	Thursday	4
16/12/2022	2022	12	December	Q4	Friday	5
17/12/2022	2022	12	December	Q4	Saturday	6
18/12/2022	2022	12	December	Q4	Sunday	7
19/12/2022	2022	12	December	Q4	Monday	1
20/12/2022	2022	12	December	Q4	Tuesday	2
21/12/2022	2022	12	December	Q4	Wednesday	3
22/12/2022	2022	12	December	Q4	Thursday	4
23/12/2022	2022	12	December	Q4	Friday	5
24/12/2022	2022	12	December	Q4	Saturday	6
25/12/2022	2022	12	December	Q4	Sunday	7

Justificación visual y psicológica: El mapa de calor revela distribuciones bidimensionales que ningún gráfico de líneas o barras puede mostrar al mismo tiempo. Usa luminosidad para codificar magnitud, activando la **Ley de Región Común**: celdas de color similar se perciben como parte del mismo patrón. Es especialmente efectivo para detectar estacionalidad intra-semanal e inter-mensual de forma simultánea.

Interpretación: Muestra en qué días y meses se concentran las ventas. Esa información es directamente accionable para decisiones de logística, staffing y campañas promocionales focalizadas.


NombreMes	Monday	Tuesday	Wednesday	Thursday	Friday	Saturday	Sunday	Total
April					8019191			8019191
August				8337017			15234388	23571405
December						8086066		8086066
February				7723400				7723400
January			16747795			7831709		24579504
July	8704432	7879126			16008949			32592507
June		7526433	23816175			7178403		38521011
March	9019136	7543252	8557897					25120285
May					8604428	8942995		17547423
November	15248908							15248908
October							8252452	8252452
September		8097039	7466802		7757575	8502021		31823437
Total	32972476	31045850	56588669	16060417	24381194	48464077	31572906	241085589

4. KPIs Ejecutivos Composición de Métodos de Pago (Cards Anillo)

Variables usadas: Cards: **Ingresos_Totales**, **Variacion_vs_PeriodoAnterior** (%), **Ticket_Promedio** · Anillo: **Metodo_Pago** con **Ingresos_Totales**

Justificación visual y psicológica: Las tarjetas KPI responden al principio de jerarquía visual: cifras en 32px Sans-Serif permiten responder "¿cómo vamos?" en menos de 3 segundos. El anillo se justifica porque **Metodo_Pago** tiene solo 2 categorías (**Efectivo**, **Tarjeta**); con más, las diferencias angulares serían imperceptibles y se necesitarían barras al 100%. La **Ley de Figura-Fondo** dirige la atención a los segmentos a través del espacio central vacío. La variación porcentual usa formato condicional (verde/rojo) como codificación semántica pre-atentiva.

Interpretación: Ofrece lectura instantánea del período. El anillo revela un reparto equilibrado: **efectivo** 53.77% (\$130 mill.) frente a **tarjeta** 46.23% (\$111 mill.). Sin dependencia crítica de un solo método de pago, el riesgo operativo es bajo.




5. Evolución de la Participación por Ciudad (Barras Apiladas al 100%)

Variables usadas: Eje X: Mes-Año · Eje Y: porcentaje de participación (0–100%) · Leyenda: Ciudad

Justificación visual y psicológica: Las barras apiladas al 100% son la codificación correcta cuando el objetivo es composición proporcional en el tiempo, no magnitud absoluta. Cada barra suma 100%, permitiendo rastrear si una ciudad gana o pierde participación de mercado. La **Ley de Continuidad** se activa en los límites entre segmentos: el ojo rastrea la frontera como si fuera una línea. Se usó paleta categórica cualitativa con máximo 6 colores para que la **Ley de Similitud** funcione sin ambigüedad.

Interpretación: Detecta si la concentración geográfica de ventas está cambiando. Una ciudad emergente que gana participación mientras la principal la pierde puede indicar saturación de mercado o éxito de expansión regional.



3.3 Interactividad y Usabilidad

F — Slicers, Interacciones y Diseño del Lienzo


Slicers estratégicos: Dos segmentadores. El primero de **Período** (Año Trimestre, tabla Calendario), estilo *Desplegable* para minimizar espacio. El segundo de **Categoría de Producto**, estilo *Lista* con selección múltiple. Ambos en la zona superior siguiendo el patrón de lectura F/Z: el usuario escanea primero esa área, así los controles se descubren antes de llegar a los gráficos.

Interacciones visuales: Todos los filtros cruzados configurados en modo **Filtrar** (no Resaltar) vía **Formato → Editar interacciones**. El modo Resaltar atenúa datos no seleccionados generando ruido visual; el modo Filtrar elimina lo irrelevante y enfoca al usuario en el subconjunto analizado.

Tipografía: Exclusivamente **Segoe UI** en todo el dashboard. Títulos de gráficos: 14px Bold · Etiquetas de ejes: 13px Regular · Valores de KPI Cards: 28–32px Light. El mínimo de 13px garantiza legibilidad sin acercamiento, cumpliendo WCAG 2.1.

Organización del lienzo (Gestalt):

- **Ley de Proximidad:** KPI Cards y anillo junto al gráfico de líneas en la fila superior (respuesta ejecutiva rápida). Detalle analítico en filas inferiores.
- **Ley de Cercado:** cada visual con fondo blanco y borde redondeado #E0E0E0 sobre lienzo #F5F5F5. Crea grupos sin líneas duras.
- **Ley de Similitud:** paleta consistente en todos los gráficos. El mismo color siempre representa la misma categoría.



4. Análisis e Interpretación de Resultados

Hallazgo 1 — Evolución temporal sin crecimiento sostenido ni colapso

El gráfico de líneas muestra ingresos que oscilan mes a mes sin una tendencia clara de crecimiento o caída a lo largo del período 2022-2023. Las 30 categorías se comportan de forma paralela: cuando sube una, las demás tienden a subir también, lo que sugiere que las fluctuaciones responden a factores externos (estacionalidad, temporadas) más que a dinámicas internas entre categorías. No hay una categoría que claramente lidere ni una que esté en declive estructural. El negocio opera de forma uniforme.

Hallazgo 2 — Distribución equilibrada sin concentración de riesgo

El cruce entre las visualizaciones revela un patrón consistente: el negocio no depende de ningún único factor. El ranking de productos muestra ingresos que decaen gradualmente de \$9.5 mill. (Door) a \$5 mill. (Worry) — sin un producto estrella que concentre el 50% de los ingresos. Los métodos de pago se dividen casi en partes iguales (efectivo 53.77% / tarjeta 46.23%). El mapa de calor expone que la actividad no se concentra en un solo día de la semana ni en un mes puntual. Ningún punto único de falla domina la estructura de ingresos.

Hallazgo 3 — Métricas base confiables tras el proceso ETL

Las 100 transformaciones aplicadas en OpenRefine produjeron un dataset íntegro: 18,000 filas sin valores nulos críticos, columnas con tipos correctos y categorías unificadas. Sobre ese modelo, las

tres medidas DAX calcularon con precisión: **Ingresos_Totales** \$241.09 mill., **Ticket_Promedio** \$8.04 mill. por transacción y **Variacion_vs_PeriodoAnterior** operativa por mes. Ninguna cifra del dashboard depende de datos sucios o de relaciones mal configuradas — los cinco ajustes de modelado documentados garantizan esa confiabilidad.

Conclusión general

El análisis temporal del dataset de ventas muestra un negocio con actividad comercial estable a lo largo de aproximadamente 13 meses. No hay señales de crecimiento acelerado ni de crisis, sino fluctuaciones propias de la demanda normal. La fortaleza estructural está en su diversificación: 30 productos, 30 ciudades, 30 categorías y dos métodos de pago con participación similar. Esa distribución reduce el riesgo operativo y hace que el negocio sea menos vulnerable a la caída de cualquier variable individual. Para el siguiente ciclo de análisis, el foco debería estar en identificar los meses y días de la semana con mayor concentración de ventas — dato que el mapa de calor ya comienza a revelar — para orientar campañas y decisiones de inventario con base en evidencia.